

Spotify Daten - und Nutzerprofilanalyse

Projektarbeit im Fach: Artificial Intelligence

Genre Klassifikation mittels Machine Learning
Explorative Nutzer Analyse

Sebastian Buresch
Marco Lichtenberger
Thomas Elias Huber
31. Juli 2025

Abstract

Dieses Projekt untersucht die Analyse von Spotify-Daten zur Erstellung eines Nutzerprofils und zur automatisierten Genreklassifikation mithilfe von Machine-Learning-Methoden. Grundlage bilden sowohl persönliche Nutzerdaten, die über die Spotify Web API abgerufen werden, als auch ein umfangreicher Kaggle-Datensatz mit Audiofeatures von mehr als 20.000 Songs. Die Arbeit umfasst eine explorative Analyse der Hörgewohnheiten, die Zuordnung von Genres zu übergeordneten Musikstilen sowie die Entwicklung eines RandomForest-Modells zur Klassifikation von Musikgenres. Zusätzlich wurden statistische Analysen wie der Zusammenhang zwischen Songlänge und Popularität durchgeführt. Die Ergebnisse zeigen, dass bestimmte Genres klar identifizierbare akustische Merkmale aufweisen, während sich ähnliche Genres schwerer trennen lassen. Das Projekt verdeutlicht, wie datengetriebene Musikinterpretation praktisch umgesetzt werden kann.

1. Einleitung

Musik ist ein zentraler Bestandteil menschlicher Kultur und ein Spiegel individueller Vorlieben. Mit der Verbreitung von Musikstreaming-Plattformen wie Spotify stehen heute große Mengen an Hör- und Metadaten zur Verfügung, die wertvolle Einblicke in das Nutzerverhalten ermöglichen. Das Ziel dieser Arbeit ist es, anhand dieser Daten sowohl das individuelle Hörprofil zu bestimmen als auch ein Modell zu entwickeln, das Songs automatisch in Genres klassifiziert.

2. Datengrundlage


Für die Analysen kamen zwei Hauptdatenquellen zum Einsatz:

1. Die Spotify Web API zur Abfrage persönlicher Nutzerdaten (Top-Tracks, Künstler, Genres). Die Authentifizierung erfolgt über OAuth, sensible Zugangsdaten werden aus einer .env-Datei geladen.
2. Ein Kaggle-Datensatz mit über 20.000 Songs und den wichtigsten Audiofeatures, darunter:
 - danceability, energy, loudness, speechiness
 - acousticness, instrumentalness, liveness, valence, tempo

3. Explorative Nutzeranalyse

Das Skript SpotifyPersonCheck.py ruft die zehn meistgehörten Songs eines Nutzers für einen bestimmten Zeitraum (short-, medium-, long-term) ab und extrahiert die zugehörigen Genres der Künstler.

Anschließend werden die häufigsten Genres gezählt und in einem Balkendiagramm visualisiert. Über ein Mapping werden ähnliche Genres zu übergeordneten Musikprofilen wie 'Rocker', 'Metalhead' oder 'Pop-Liebhaber' zusammengefasst, wodurch ein grobes Nutzerprofil entsteht.



4. Genreklassifikation mit Machine Learning

Technische Details zur Machine-Learning-Implementierung

Für die automatisierte Genreklassifikation wurde ein RandomForestClassifier aus der Bibliothek scikit-learn verwendet. Dieses Ensemble-Verfahren besteht aus einer Vielzahl von Entscheidungsbäumen, die jeweils auf zufällig ausgewählten Teilmengen der Trainingsdaten und -features trainiert werden. Die finale Vorhersage ergibt sich aus der Mehrheitsentscheidung aller Bäume (Voting-Verfahren). Dieses Vorgehen reduziert die Varianz einzelner Entscheidungsbäume und führt zu einer robusteren Generalisierung auf unbekannte Daten.

Vorverarbeitung der Daten:

- Aus dem Kaggle-Datensatz wurden ausschließlich numerische Audiofeatures verwendet, darunter danceability, energy, loudness, speechiness, acousticness, instrumentalness, liveness, valence und tempo.
- Um die Klassifikation zu stabilisieren, wurden die Daten auf die 15 häufigsten Genres reduziert. Dies senkt die Klassenanzahl und verbessert die Vorhersagequalität.
- Fehlende Werte wurden entfernt, um Konsistenz zu gewährleisten.

Trainings- und Testaufteilung:

- Die Daten wurden im Verhältnis 80 % Training zu 20 % Test zufällig aufgeteilt (train_test_split).
- Hyperparameter wie n_estimators=100 (Anzahl der Bäume) und random_state=42 (Reproduzierbarkeit) wurden gesetzt.

Evaluierung:

- Neben der Accuracy wurden Precision, Recall und F1-Score pro Klasse berechnet, um ein differenzierteres Bild der Modellleistung zu erhalten.

- Für klar definierte Genres wie minimal-techno oder metalcore wurden F1-Scores über 0.6 erreicht, während überlappende Genres wie pop und pop-film deutlich niedrigere Werte erzielten.
- Eine Konfusionsmatrix wurde erstellt, um häufige Fehlklassifikationen visuell zu identifizieren.

Feature-Wichtigkeit:


- Der RandomForest-Algorithmus liefert eine Rangliste der wichtigsten Features basierend darauf, wie stark sie zur Trennung der Klassen beitragen.
- In diesem Projekt waren die wichtigsten Merkmale:
 1. acousticness (13.2 %)
 2. danceability (12.2 %)
 3. instrumentalness (12.1 %)
- Diese Werte deuten darauf hin, dass akustische Eigenschaften und Tanzbarkeit maßgeblich zur Genreunterscheidung beitragen.

Zusammenfassung:

Das gewählte Modell eignet sich gut, um einen ersten funktionsfähigen Genreklassifikator zu erstellen. Für zukünftige Arbeiten könnten komplexere Modelle wie neuronale Netze oder Gradient-Boosting-Algorithmen (z. B. XGBoost) in Betracht gezogen werden, um die Genauigkeit bei ähnlichen Genres zu steigern.

Im Skript GenreClassifikation.py wird ein RandomForestClassifier verwendet, um Musikgenres auf Basis von Audiofeatures vorherzusagen. Das Modell wird auf den 15 häufigsten Genres trainiert, um die Genauigkeit zu erhöhen. Die Aufteilung in Trainings- und Testdaten erfolgt im Verhältnis 80/20. Die Feature-Wichtigkeit wird berechnet und zeigt, dass Merkmale wie acousticness, danceability und instrumentalness den größten Einfluss auf die Genrevorhersage haben.

Das Modell erreichte eine Genauigkeit von ca. 49 %, mit besonders guten Ergebnissen für klar abgegrenzte Genres wie 'minimal-techno' oder 'metalcore'..



5. Statistische Analysen

Neben der Genreklassifikation wurden weitere Analysen durchgeführt, um Zusammenhänge zwischen musikalischen Merkmalen zu untersuchen. Das Skript `LengthVsPopularity.py` berechnet die Korrelation zwischen Songlänge (in Minuten) und Popularität und erstellt entsprechende Visualisierungen. Ein ähnlicher Ansatz könnte auch für die Analyse von Energy und Tempo (`EnergyVsTempo.py`) angewendet werden.

6. Ergebnisse und Diskussion


Die explorative Analyse liefert ein klares Bild der individuellen Hörgewohnheiten. Das Machine-Learning-Modell zeigt, dass eine Genreklassifikation auf Basis der ausgewählten Audiofeatures möglich ist, wenn auch mit Einschränkungen bei Genres mit ähnlichen Merkmalen. Die zusätzlichen statistischen Analysen bieten interessante Einblicke in Trends wie die Beliebtheit kürzerer oder längerer Songs.


Zusätzliche statistische Auswertungen

Neben der Genreklassifikation wurden verschiedene statistische Analysen durchgeführt, um Zusammenhänge zwischen verschiedenen Audiofeatures und der Popularität von Songs zu untersuchen.

1. Songlänge vs. Popularität:



- Die Dauer der Songs (in Minuten) wurde gegen die Popularität aufgetragen.
- Die Analyse zeigte eine geringe bis moderate Korrelation.





2. Energy vs. Tempo:

- Die Beziehung zwischen dem Energy-Level und dem Tempo wurde untersucht.
- Ein positiver Zusammenhang konnte bei bestimmten Genres festgestellt werden.



7. Fazit und Ausblick

Das Projekt zeigt, wie öffentlich verfügbare Datenquellen wie die Spotify API und Datensätze von Plattformen wie Kaggle kombiniert werden können, um ein umfassendes Bild der Musikpräferenzen zu erhalten und Machine-Learning-Modelle zu trainieren. Zukünftige Arbeiten könnten komplexere Modelle (z. B. neuronale Netze) einbeziehen oder zusätzliche Datenquellen wie Songtexte für eine noch präzisere Genreklassifikation nutzen.

8. Literaturverzeichnis

- Spotify Developer. (2023). Spotify Web API Documentation. <https://developer.spotify.com/documentation/web-api/>
- Kaggle. (2023). Spotify Dataset. <https://www.kaggle.com/datasets>
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Python Docx. (2023). Create and Update Word Documents. <https://python-docx.readthedocs.io/>